

NANODEGREE - PROJETO FINAL DE MACHINE LEARNING

Predição do Abandono do Tratamento de Tuberculose

Aprendizado de máquina aplicado aos microdados do SINAN / DataSUS

Grupo: Rafael S. Pedra - [demais integrantes]

2026

O problema: abandono do tratamento

A tuberculose é causada pela bactéria *Mycobacterium tuberculosis*, afeta os pulmões e é altamente transmissível quando ativa.

Tratamento gratuito no SUS, mas longo: no mínimo 6 meses de antibióticos.

Consequência: altas taxas de abandono.

Pior desfecho

o paciente não se cura e pode agravar

Transmissão

TB ativa segue circulando na comunidade

Resistência

tratamento interrompido gera cepas resistentes

Da pra prever quem vai abandonar?

Conseguimos estimar, já no diagnóstico, a probabilidade de um paciente abandonar o tratamento?

Objetivo

Construir um algoritmo que informe a probabilidade de abandono, **útil para priorizar pacientes de risco** (visitas, tratamento observado, apoio social) e, no futuro, integrar a uma interface para os profissionais de saúde.

A dor que atendemos: a equipe não consegue acompanhar de perto todos os pacientes - o modelo ajuda a focar nos casos certos.

Microdados do SINAN / DataSUS

Cada linha = um caso notificado de tuberculose. Aplicamos filtros para casos comparáveis.

2.188.471

registros brutos (todos os anos, 97 variáveis)

563.894

casos validos (adultos, TB pulmonar, sensíveis)

562.632 / 631 / 631

treino / teste1 / teste2

Divisao temporal (treinar no passado, prever o futuro): treino < 2025 | teste = 2025 dividido ao meio.

Como tratamos os dados

Variável-alvo (Itfu)

1 = abandono

0 = cura

derivado de SITUA_ENCE (só cura/abandono).

Pre-processamento (estilo das aulas)

- Idade decodificada; criada a feature de atraso diagnóstico->tratamento
- Ausentes: numericas pela mediana; categoricas viram a categoria 'ignorado'
- Normalização (StandardScaler) + codificação (OneHotEncoder)
- Removido vazamento (SITUA_ENCE e exames do 6o mes)
- Tudo num ColumnTransformer da Scikit-Learn (reprodutível)

Dois modelos, um protocolo

Regressão Logística

LINHA DE BASE (BASELINE)

Simples, rápida e interpretável. Referência de comparação.

Rede Neural (Keras)

MODELO PRINCIPAL

2 camadas ocultas + dropout, saída sigmoide (probabilidade).

Protocolo de avaliação

1) treina no treino -> avalia no teste1 2) junta teste1 ao treino -> avalia no teste2

Desbalanceamento tratado com `class_weight` (SMOTE inviável em ~560 mil linhas). Conjuntos de teste usados o mínimo possível.

Métricas escolhidas (antes de treinar)

Como o alvo é desbalanceado, a acurácia engana. Priorizamos:

Recall

achar quem vai abandonar
(prioridade)

F1

equilíbrio entre precisão e recall

ROC-AUC


robusto a prevalência

Erro mais grave: deixar passar um abandono (falso negativo). Por isso o recall recebe atenção especial.

Dois modelos, desempenho semelhante

Modelo / Teste	ROC-AUC	F1	Recall
LogReg - Teste1	0,78	0,68	0,76
Rede Neural - Teste1	0,79	0,68	0,78
LogReg - Teste2	0,75	0,79	0,77
Rede Neural - Teste2	0,76	0,78	0,76

Desempenho próximo entre os modelos: a rede neural leva leve vantagem no ROC-AUC; a regressão logística é competitiva e mais simples de explicar. Recall alto (~0,76-0,78) nos dois.




Por que a prevalência muda tanto?

O abandono passa de 19% (treino) para 44% e 69% (testes de 2025).

Não é erro: é censura a direita. A cura só é registrada após ~6 meses; em 2025 os casos já encerrados são, em sua maioria, abandonos (que encerram cedo).

Por isso priorizamos a ROC-AUC e interpretamos acurácia/precisão com cautela nos testes.




O que pesa na predição?

Permutation Importance + SHAP apontam fatores coerentes com a literatura:

- Alcoolismo e uso de drogas
- Situação de rua
- Coinfecção por HIV
- Ausência de tratamento observado (TDO)

Teste de sanidade: paciente fictício com agravos e sem TDO recebeu probabilidade muito maior - o modelo aprendeu padrões plausíveis.



Um app para o profissional de saúde

O profissional insere poucas informações e recebe:

- a probabilidade de abandono
- uma classificação de risco (baixo/médio/alto)
- ações sugeridas (ex.: TDO, visita, apoio social)

*Motor: modelo reduzido a 8 variáveis (menos campos = mais uso).
MLOps: monitorar, reavaliar e versionar. Ética: direcionar MAIS apoio a quem tem risco, nunca negar cuidado.*

Triagem de Risco de Abandono

Tratamento de Tuberculose · apoio a decisão do profissional

Idade (anos)

28

Uso de álcool

Sim

Uso de drogas

Sim

Tabagismo

Sim

HIV

Positivo

Trat. observado (TDO)

Não

Situação de rua

Sim

Benefício social

Não

Avaliar risco

PROBABILIDADE DE ABANDONO

97%

Risco ALTO

Ações sugeridas

- Priorizar Tratamento Diretamente Observado (TDO)
- Visita domiciliar / busca ativa preventiva
- Acionar apoio social
- Contato frequente nas primeiras semanas

*Ferramenta de apoio a decisão (dados do SINAN).
Não substitui a avaliação clínica.*

CONSIDERAÇÕES FINAIS

E possível prever o risco de abandono

- Pipeline reprodutível, do dado bruto ao modelo
- Dois modelos com desempenho semelhante (ROC-AUC ~0,75-0,79)
- Fatores de risco coerentes com a literatura (xAI)

Próximos passos

- App simples para o profissional de saúde (poucos campos de entrada)
- Monitoramento do modelo em produção (MLOps) e reavaliação periódica
- Calibração de probabilidades para apoio a decisão clínica

Obrigado!

Perguntas?

Grupo TB - Predição do Abandono do Tratamento de Tuberculose - 2026